

Analisis Komparatif Model Machine Learning dengan Teknik Feature Selection, Reduksi Dimensi (PCA), dan Over-sampling (SMOTE-ADASYN) untuk Prediksi Loan Default

Alma Khusnia*¹, Amelia Nova Safitri², Sharfina Ardhiyanti Anam³

Institut Teknologi Sepuluh Nopember, Jalan Raya ITS, Keputih, Kota Surabaya, (03) 1599 4251

E-mail : 5025231063@student.its.ac.id*¹, 5025231041@student.its.ac.id²,

5025231111@student.its.ac.id³

Received 8 December 2025; Revised 19 December 2025; Accepted 20 December 2025

Abstract - Sektor keuangan menghadapi tantangan signifikan dalam memprediksi risiko gagal bayar (*loan default*). Hal tersebut akibat dari ketidakseimbangan distribusi kelas antara debitur berstatus lancar dan debitur yang mengalami gagal bayar, sehingga menyebabkan model *machine learning* cenderung bias terhadap kelas mayoritas dan kurang efektif dalam mengidentifikasi debitur berisiko tinggi. Untuk mengatasi permasalahan tersebut, penelitian ini melakukan analisis komparatif terhadap beberapa model *machine learning* dengan menerapkan teknik *feature selection*, reduksi dimensi menggunakan *Principal Component Analysis* (PCA), serta penanganan ketidakseimbangan data melalui metode *oversampling* SMOTE dan ADASYN. Dataset diproses menggunakan *pipeline* yang mencakup tahap *preprocessing*, *resampling*, dan pelatihan model, dengan lima algoritma yang digunakan, yaitu LightGBM, Random Forest, Decision Tree, K-Nearest Neighbors (KNN), dan Multi-Layer Perceptron (MLP). Pengujian dilakukan melalui tiga skenario, yaitu penerapan *feature selection*, PCA, dan tanpa keduanya, kemudian masing-masing skenario dikombinasikan dengan *oversampling* SMOTE dan ADASYN. Evaluasi kinerja model difokuskan pada metrik *Recall* dan *F1-Score* untuk kelas minoritas (*defaulter*), dengan tujuan mengidentifikasi kombinasi metode dan model terbaik dalam meningkatkan akurasi deteksi debitur berisiko gagal bayar.

Keywords - *Machine Learning, Loan Default, Feature Selection, Principal Component Analysis, Oversampling*

1. PENDAHULUAN

Sektor perbankan dan lembaga keuangan menghadapi tantangan serius dalam pengelolaan risiko kredit, terutama ketika peminjam tidak mampu memenuhi kewajiban pembayaran pinjaman (*loan default*). Kondisi tersebut berpotensi menimbulkan kerugian finansial yang signifikan serta mengganggu stabilitas operasional lembaga keuangan. Oleh karena itu, kemampuan untuk memprediksi potensi default secara akurat menjadi aspek krusial dalam manajemen risiko kredit. Berbagai penelitian menunjukkan bahwa sistem prediksi risiko kredit yang andal berperan penting dalam mendukung pengambilan keputusan kredit yang lebih aman dan terukur [9], [14].

Perkembangan *Machine Learning* (ML) dalam dua dekade terakhir telah menjadikannya pendekatan yang banyak digunakan dalam prediksi risiko kredit. Model berbasis pohon keputusan seperti Decision Tree dan Random Forest terbukti mampu mengklasifikasikan risiko peminjam secara efektif dan telah banyak diadopsi baik dalam penelitian maupun praktik industri [11], [14]. Selain itu, algoritma *gradient boosting* modern seperti LightGBM menunjukkan keunggulan dalam efisiensi komputasi dan kemampuan generalisasi, sehingga semakin relevan untuk pengolahan data kredit berskala besar [7], [9].

Meskipun demikian, data kredit pada kondisi nyata umumnya memiliki permasalahan ketidakseimbangan kelas (*imbalanced dataset*), di mana jumlah peminjam yang mengalami gagal bayar (*Defaulter*) jauh lebih sedikit dibandingkan peminjam yang membayar tepat waktu (*Non-Defaulter*). Ketidakseimbangan ini menyebabkan model ML cenderung bias terhadap kelas mayoritas dan menghasilkan nilai akurasi yang tinggi, namun memiliki kinerja yang rendah dalam mendeteksi kelas minoritas [5], [12]. Kesalahan klasifikasi berupa *False Negative*, yaitu ketika *Defaulter* diklasifikasikan sebagai *Non-Defaulter*, dapat menimbulkan risiko kerugian finansial yang besar bagi lembaga keuangan [5], [13].

Untuk mengatasi permasalahan tersebut, berbagai teknik penanganan data tidak seimbang telah dikembangkan, di antaranya metode *oversampling* seperti Synthetic Minority Over-sampling Technique (SMOTE) dan Adaptive Synthetic Sampling (ADASYN). Metode ini terbukti mampu meningkatkan representasi kelas minoritas dan memperbaiki kinerja model prediksi pada kasus kredit dan loan default [2], [10], [12]. Selain itu, penerapan Feature Selection dan reduksi dimensi menggunakan Principal Component Analysis (PCA) juga banyak digunakan untuk meningkatkan kualitas fitur input, mengurangi redundansi data, serta meningkatkan stabilitas dan efisiensi model [3].

Berdasarkan permasalahan dan kajian literatur tersebut, penelitian ini mengusulkan pendekatan komparatif dengan mengintegrasikan Feature Selection, PCA, serta teknik oversampling SMOTE dan ADASYN ke dalam *pipeline* pemodelan *Machine Learning*. Lima algoritma prediktif digunakan, yaitu LightGBM, Random Forest, Decision Tree, K-Nearest Neighbors (KNN), dan Multi-Layer Perceptron (MLP). Evaluasi difokuskan pada metrik *Recall* dan *F1-Score* untuk kelas minoritas (*Defaulter*) sebagai indikator utama keberhasilan model dalam menangani data tidak seimbang. Nilai kebaruan (*novelty*) dari penelitian ini terletak pada analisis komparatif yang sistematis terhadap kombinasi teknik seleksi fitur, reduksi dimensi, dan metode oversampling lintas berbagai algoritma ML, sehingga diharapkan mampu memberikan rekomendasi yang lebih komprehensif dan aplikatif bagi lembaga keuangan dalam meningkatkan akurasi prediksi loan default.

2. METODE PENELITIAN

2.1. Dataset Description

Dataset yang digunakan pada penelitian ini adalah [Loan Default Prediction Dataset](#) yang diperoleh dari Kaggle. Terdiri dari 67.463 baris dan 35 fitur pada data train serta 28.913 baris dan 34 fitur pada data test. Dataset ini mencakup informasi yang berkaitan dengan karakteristik peminjaman, kondisi keuangan, serta riwayat kredit yang relevan untuk memprediksi kemungkinan terjadinya gagal bayar. Seluruh fitur memiliki peran penting dalam implementasi profil risiko peminjam, sehingga memungkinkan model untuk mempelajari pola perilaku kredit secara komprehensif. Target yang diprediksi adalah Loan Status, yaitu 1 untuk peminjam yang masuk kategori defaulter dan 0 untuk peminjam non-defaulter. Untuk mendukung pemahaman lebih lanjut, dapat dilihat pada tabel berikut.


Tabel 2.1. Penjelasan *Dataset*

Kelompok Fitur	Anggota Fitur	Deskripsi
Informasi Peminjaman	<i>Loan Amount, Funded Amount, Funded Amount Investor, Term, Interest Rate, Grade,</i>	Menjelaskan detail utama pinja manseperti jumlah, durasi, bunga, serta penilaian risiko kredit peminjam

	<i>Sub Grade, Payment Plan, Loan Title</i>	
Profil Peminjaman	<i>Employment Duration, Home Ownership, Verification Status, Application Type</i>	Menggambarkan karakteristik dasar peminjam, termasuk lama bekerja, status rumah, dan status verifikasi data
Kondisi Finansial	<i>Debt to Income, Revolving Balance, Revolving Utilities, Total Current Balance, Total Revolving Credit Limit</i>	Menunjukkan kondisi keuangan peminjam melalui rasio utang, saldo kredit bergulir, dan batas kredit yang tersedia
Riwayat Kredit dan Pembayaran	<i>Delinquency - two years, Inquires - six months, Open Account, Public Record, Total Accounts, Accounts Delinquent, Total Collection Amount, Total Received Late Fee, Total Received Interest, Recoveries, Collection Recovery Fee, Collection 12 months Medical</i>	Riwayat kredit dan perilaku pembayaran, termasuk keterlambatan, riwayat penagihan, dan aktivitas akun
Informasi Pelengkap	<i>Batch Enrolled, Initial List Status, Last week Pay</i>	Informasi tambahan terkait status awal dan riwayat pengajuan pinjaman
Target	<i>Loan Status</i>	Menunjukkan apakah peminjam masuk kategori default atau tidak

2.2. Perancangan Sistem

Berisi alur kerja sistem (*flowcart*) dan penjelasan detil setiap tahapan proses seperti yang ditunjukkan pada gambar. Proses dimulai dengan pemilihan dataset, kemudian dilanjutkan dengan *pre-processing* seperti penanganan outlier, dan *feature encoding*. Dataset lalu dibagi menjadi data *train* dan data *validation*. Selanjutnya, dilakukan *feature scaling*. Model kemudian dilatih, digunakan untuk prediksi, dan dievaluasi menggunakan metrik performa guna menilai akurasi hasil klasifikasi.



Gambar 2.2 Alur Proses Perancangan Sistem

1. Pemilihan Dataset

Tahap pertama dalam desain untuk menentukan dataset yang relevan dan sesuai dengan tujuan penelitian. Dataset yang digunakan pada penelitian ini adalah [Loan Default Prediction Dataset](#) yang diperoleh dari Kaggle. Target yang diprediksi adalah Loan Status, yaitu 1 untuk peminjam yang masuk kategori *defaulter* dan 0 untuk peminjam non-*defaulter*. Dataset ini dipilih karena menyediakan data peminjaman yang cukup komprehensif, mencakup informasi demografis peminjaman, variabel finansial, hingga karakteristik pinjaman sehingga sesuai untuk membangun model klasifikasi berbasis *supervised learning*.

2. Exploratory Data Analysis

Tahap selanjutnya yaitu *Exploratory Data Analysis* (EDA) yang dilakukan untuk memahami karakteristik dan kualitas dataset sebelum *pre-processing data*. Pada tahap ini, dilakukan analisis terhadap struktur data untuk mengetahui jumlah distribusi, jumlah fitur, serta tipe data yang digunakan. Selanjutnya, dilakukan pemeriksaan *missing values*, nilai duplikat, serta *wrong value* pada setiap fitur untuk mengidentifikasi data yang kurang lengkap. Analisis distribusi variabel target *Loan Status* menunjukkan adanya ketidakseimbangan kelas (*class imbalance*), di mana jumlah peminjam non-*defaulter* lebih dominan dibandingkan peminjam *defaulter*, sehingga perlu diperhatikan dalam proses pelatihan model. Selain itu, dilakukan visualisasi dan analisis statistik pada fitur numerik maupun kategorikal untuk memahami pola sebaran data, nilai rata-rata, serta rentang nilai setiap variabel. Hubungan antara fitur dan variabel target juga dianalisis untuk mengidentifikasi fitur-fitur yang berpotensi memengaruhi risiko gagal bayar, serta dilakukan analisis korelasi antar fitur numerik untuk mendeteksi kemungkinan redundansi atau hubungan linear yang kuat antar fitur.

3. Pre-Processing

Tahap *pre-processing* dilakukan untuk memastikan kualitas data sebelum digunakan dalam proses pelatihan model *machine learning*. Pada penelitian ini, *pre-processing* berfokus pada peningkatan konsistensi dan representasi data melalui dua langkah utama, yaitu *handling outlier* dan *feature encoding*. Karena dataset tidak memiliki *missing value*, proses dapat difokuskan pada distribusi fitur numerik serta transformasi fitur kategori agar sesuai untuk algoritma klasifikasi.

Penanganan data outlier dilakukan dengan visualisasi data terlebih dahulu agar lebih mudah mengidentifikasi keberadaan outlier. Data outlier akan ditangani agar tidak memengaruhi proses pelatihan dan performa model secara keseluruhan. Proses penanganan outlier yang dilakukan dijabarkan dengan urutan berikut:

1. Melihat visualisasi boxplot dan countplot

Visualisasi boxplot digunakan untuk menampilkan penyebaran data numerik, termasuk median, kuartil, dan pencilan (*outlier*). Selain itu, juga untuk memastikan keberadaan nilai ekstrem pada masing-masing fitur.

2. Mendeteksi rasio data outlier dengan pendekatan *quantile*

Metode deteksi outlier berbasis kuantil menggunakan pendekatan IQR. Prosedur ini menghitung batas bawah dan atas dari data menggunakan rumus:

$$IQR = Q3 - Q1, \quad \text{Lower} = Q1 - 1.5 \times IQR, \\ \text{Upper} = Q3 + 1.5 \times IQR$$

Data yang berada di luar batas ini diklasifikasikan sebagai outlier.

3. Penanganan outlier dengan *winsorization (clipping)*

Nilai di bawah batas bawah diganti dengan *lower bound* dan nilai di atas batas atas diganti dengan *upper bound*, sehingga distribusi menjadi lebih stabil tanpa menghilangkan data.

Setelah outlier ditangani, proses dilanjutkan dengan *feature encoding* untuk mengubah variabel kategori menjadi numerik. Beberapa fitur kategori seperti *Grade*, *Employment Duration*, *Verification Status*, *Initial List Status*, dan *Application Type* diubah menggunakan metode *one-hot encoding* yakni mengubah setiap kategori unik dalam suatu fitur menjadi kolom biner terpisah (0 atau 1) tanpa menghilangkan kategori pertama (*drop_first=False*). Pendekatan ini dipilih untuk memastikan bahwa seluruh kategori tetap terwakili dan tidak ada informasi label yang terbuang, terutama ketika model yang digunakan tidak sensitif terhadap redundansi antar fitur, seperti *Random Forest* dan *LightGBM*. Sementara itu, fitur dengan *cardinality* tinggi dan isi datanya tidak berguna seperti *Loan Title*, *Batch Enrolled*, *Sub Grade*, *Payment Plan*, *Accounts Delinquent*, dan ID dihapus karena berpotensi meningkatkan jumlah dimensi secara berlebihan tanpa memberikan kontribusi signifikan terhadap performa model. Hasil akhir encoding menghasilkan dataset numerik yang siap digunakan pada proses training model.

4. ***Split Dataset***

Setelah dataset melalui proses pembersihan, dataset dibagi menjadi dua bagian utama, yakni data latih (*training set*) dengan proporsi 80% dan data validasi (*validation set*) dengan proporsi 20%. Pembagian ini memungkinkan model untuk belajar dari sebagian data dan diuji performanya pada data yang belum pernah dilihat sebelumnya, guna menghindari overfitting.

5. ***Feature Scaling***

Pre-processing lanjutan yaitu *feature scaling* yang dilakukan setelah dataset dibagi menjadi data *train* dan data *validation*. Bagian ini menerapkan teknik *Standard Scaler*, yaitu metode normalisasi yang mentransformasikan fitur numerik agar memiliki nilai rata-rata (*mean*) 0 dan standar deviasi 1. Pada data *train*, dilakukan proses *fit_transform*, sedangkan pada data *validation* hanya diterapkan *transform*. Pendekatan ini penting terutama ketika model machine learning yang digunakan sensitif terhadap perbedaan skala data, seperti *k-Nearest Neighbors*, MLP, dan regresi berbasis gradien. Sehingga, menggunakan hasil yang diperoleh dari data *train*, agar skala dan representasi data tetap konsisten selama proses pelatihan model.

6. ***Pengujian Model***

Selanjutnya, model dilatih menggunakan data *train*. Proses ini melibatkan beberapa algoritma machine learning untuk membandingkan akurasi model terhadap algoritma yang berbeda. Berikut algoritma yang digunakan dalam proses pelatihan model:

a. ***K-Nearest Neighbor (KNN)***

K-Nearest Neighbor (KNN) adalah algoritma *Machine Learning* non-parametrik yang digunakan untuk klasifikasi dan regresi. KNN termasuk dalam kategori *instance-based learning* atau *lazy learning* karena tidak melalui fase pelatihan eksplisit untuk membuat model, melainkan menyimpan seluruh data pelatihan sebagai referensi. KNN didasarkan pada prinsip bahwa sampel data baru akan diklasifikasikan ke dalam kelas yang paling sering muncul di antara tetangga terdekatnya. Proses klasifikasi KNN dimulai dengan menghitung jarak antara

sampel data baru dengan semua sampel data latih, yang umumnya menggunakan metrik Jarak Euclidean yang dirumuskan sebagai berikut:

$$d(p, q) = \sqrt{\sum_{i=1}^n (p_i - q_i)^2}$$

Setelah jarak dihitung, KNN akan mengidentifikasi K sampel terdekat (*nearest neighbor*) dari sampel data baru tersebut dan menentukan kelasnya berdasarkan mayoritas suara (*majority voting*). KNN sangat bergantung pada nilai K yang optimal dan metrik jarak yang digunakan, serta membutuhkan pra-pemrosesan *scaling* karena sensitif terhadap skala fitur data.

b. Multi-Layer Perceptron (MLP)

Multi-Layer Perceptron (MLP) adalah arsitektur jaringan saraf tiruan (*Artificial Neural Network/ANN*) yang berperan sebagai fondasi dari banyak model jaringan saraf yang lebih kompleks. MLP dikategorikan sebagai *feedforward neural network* karena informasi bergerak dalam satu arah, dari lapisan input, melalui lapisan tersembunyi (*hidden layers*), menuju lapisan output. *Multi-Layer Perceptron* (MLP) dibangun dari tiga jenis lapisan neuron yang saling terhubung. Lapisan Input (Input Layer) menerima fitur mentah dari data. Data kemudian melewati Lapisan Tersembunyi (*Hidden Layer*), yang merupakan pusat pemrosesan non-linear dengan adanya fungsi aktivasi. Lapisan tersembunyi inilah yang memungkinkan MLP menyelesaikan masalah kompleks yang tidak dapat dipecahkan oleh model linear. Terakhir, Lapisan Output (*Output Layer*) menghasilkan prediksi akhir, biasanya menggunakan satu neuron dengan fungsi Sigmoid untuk klasifikasi biner, seperti dalam prediksi loan default.

Setiap neuron dalam MLP melakukan dua operasi utama. Proses ini dimulai dengan Penjumlahan Berbobot (*Weighted Sum*), yang dirumuskan sebagai:

$$z = \sum_{i=1}^n (x_i w_i) + b$$

yang kemudian hasil penjumlahan berbobot ini dilewatkan melalui Fungsi aktivasi (Activation Function) non-linear seperti ReLU atau sigmoid yang secara umum dirumuskan sebagai:

$$a = f(z)$$

Proses pelatihan MLP dilakukan menggunakan algoritma *Backpropagation* yang berfungsi untuk meminimalkan *error* prediksi. Pelatihan diawali dengan *Forward Pass*, dimana input dialirkan melalui jaringan untuk menghasilkan prediksi, yang kemudian selisih antara prediksi dan target sebenarnya diukur menggunakan *Loss Function*. Error ini kemudian disebarkan kembali ke belakang melalui *Backward Pass* untuk menentukan kontribusi error dari setiap bobot dan bias. Akhirnya, Penyesuaian Bobot dilakukan secara iteratif menggunakan algoritma

optimasi untuk memodifikasi bobot dan bias sehingga error keseluruhan model dapat diminimalkan dan kemampuan model meningkat.

c. Decision Tree

Decision Tree merupakan algoritma *supervised learning* yang digunakan untuk tugas klasifikasi maupun regresi yang merepresentasikan proses pengambilan keputusan secara **hierarkis**. Dalam *decision tree*, proses pemisahan dilakukan melalui pemilihan atribut yang memberikan kualitas split terbaik berdasarkan metrik seperti *Gini Impurity* atau *Information Gain*. Setiap *node* internal merepresentasikan pengujian pada suatu atribut, cabang mewakili hasil pengujian, dan *leaf node* memberikan prediksi kelas. Model ini bekerja dengan prinsip *recursive partitioning*, yaitu membagi ruang fitur secara berulang hingga mencapai tingkat homogenitas tertentu atau hingga memenuhi kriteria penghentian.

Secara matematis, kualitas pemisahan dapat diukur menggunakan *Gini Impurity* yang dirumuskan sebagai:

$$Gini(D) = 1 - \sum_{i=1}^C p_i^2$$

dengan p_i adalah proporsi kelas ke- i dalam subset data D . Split terbaik dipilih berdasarkan penurunan *impurity*:

$$\Delta Gini = Gini(D) - \sum_{j=1}^k \frac{|D_j|}{|D|} Gini(D_j)$$

Decision Tree memiliki kelebihan berupa interpretabilitas tinggi dan kemampuan menangkap hubungan nonlinear. Namun, model ini mudah mengalami **overfitting**, terutama pada dataset berukuran besar atau dengan fitur yang saling berkorelasi. Hal ini juga diamati oleh Madaan et al. (2021), di mana *Decision Tree* menghasilkan struktur sangat dalam ($depth = 241$) sehingga performanya kurang stabil pada data uji.

d. Random Forest

Random Forest merupakan metode *ensemble learning* berbasis bagging (*bootstrap aggregating*) yang menggabungkan banyak pohon keputusan untuk menghasilkan prediksi yang lebih stabil dan akurat. Setiap pohon dilatih pada sampel *bootstrap* dari data pelatihan, dan pada setiap split hanya subset acak dari fitur yang dipertimbangkan. Proses ini memperkenalkan dua macam keacakan (data dan fitur) yang secara signifikan mengurangi risiko *overfitting* yang sering terjadi pada pohon tunggal. Secara formal, jika terdapat B pohon keputusan $h_b(x)$ yang dilatih dari sampel *bootstrap*, maka prediksi *Random Forest classifier* diperoleh melalui voting mayoritas:

$$\hat{y} = \text{mode}\{h_1(x), h_2(x), \dots, h_B(x)\}$$

Pada kasus regresi, prediksi diperoleh dari nilai rata-rata:

$$\hat{y} = \frac{1}{B} \sum_{b=1}^B h_b(x)$$

Dengan mekanisme ini, *Random Forest* mampu menurunkan *varians* model tanpa meningkatkan bias secara signifikan. Madaan et al. (2021) menunjukkan bahwa *Random Forest* memberikan performa lebih unggul dibanding *Decision Tree*. Model ini juga lebih efisien dalam menangani dataset besar serta lebih tahan terhadap *outlier* dan multikolinearitas.

e. LightGBM

LightGBM merupakan algoritma *gradient boosting* yang dikembangkan Microsoft sebagai pengembangan dari *Gradient Boosting Decision Tree* (GBDT). Seperti GBDT, *LightGBM* membangun model secara bertahap dengan menambahkan pohon keputusan baru yang bertujuan memperbaiki kesalahan dari pohon-pohon sebelumnya. Berbeda dengan GBDT klasik yang hanya menggunakan gradien orde pertama, *LightGBM* menggunakan gradien orde pertama (*first-order gradient*) dan orde kedua (*second-order gradient*) dari fungsi *loss* sehingga proses optimasinya menjadi lebih stabil dan akurat. *LightGBM* meminimalkan fungsi *loss* menggunakan *boosting* berbasis pohon, yang secara umum dirumuskan sebagai:

$$\hat{f}(x) = \arg \min_{y,x} E L(y_1, f(x))$$

dan model akhir merupakan gabungan dari banyak pohon keputusan:

$$f_k(x) = \sum_{i=1}^k f_1(x)$$

Nilai optimal pada tiap *leaf* dihitung menggunakan gradien pertama dan kedua sebagai berikut:

$$-\frac{\left(\sum_{i \in I_j} g_i\right)^2}{\sum_{i \in I_j} h_i + \lambda}$$

Dengan memanfaatkan informasi gradien orde pertama dan kedua, *LightGBM* mampu melakukan proses pembelajaran yang lebih efisien dan stabil dibandingkan metode *boosting* konvensional. Kemampuan ini menjadikan *LightGBM* sebagai salah satu model yang unggul dalam menangani dataset berukuran besar maupun fitur yang kompleks

6. Evaluasi Metrik

Evaluasi performa model dilakukan menggunakan metrik *Recall* dan *F1-Score* sebagai metrik utama. *Recall* digunakan untuk mengukur kemampuan model dalam

mendeteksi seluruh nasabah yang berpotensi mengalami gagal bayar. Metrik ini menjadi sangat penting karena pada konteks prediksi risiko kredit, kegagalan mendeteksi defaulter (*false negative*) dapat menimbulkan kerugian yang jauh lebih besar dibandingkan kesalahan memprediksi non-defaulter sebagai defaulter.

Selain itu, *F1-Score* digunakan untuk memberikan penilaian yang lebih seimbang dengan mempertimbangkan kedua aspek, yaitu ketepatan model (*precision*) dan kemampuan mendeteksi kelas positif (*recall*). Penggunaan *F1-Score* memastikan bahwa model tidak hanya fokus memaksimalkan salah satu metrik saja, tetapi menghasilkan performa yang stabil meskipun data memiliki distribusi kelas yang tidak seimbang. Dengan kombinasi *recall* dan *F1-score*, evaluasi model menjadi lebih representatif terhadap tujuan analisis, yaitu meminimalkan risiko kredit melalui deteksi defaulter yang lebih akurat dan konsisten.

2.3. Skenario Pengujian

Skenario pengujian dirancang untuk mengevaluasi secara komprehensif kinerja kelima model (LightGBM, Random Forest, Decision Tree, KNN, dan MLP) dalam tiga kondisi pra-premosesan data yang berbeda. Evaluasi difokuskan pada kemampuan model dalam menangani masalah imbalanced data dan memprediksi kelas minoritas (defaulter).

2.3.1. Skenario Pengujian 1: Tanpa Fitur Seleksi, Seleksi Fitur, dan PCA

Skenario pengujian pertama bertujuan untuk membandingkan efektivitas berbagai teknik reduksi fitur, meliputi:

- a. Tanpa fitur seleksi (*baseline*)
- b. Seleksi fitur (*Kbest*)
- c. *Principal Component Analysis* (PCA) sebagai metode transformasi fitur

Pada tahap ini, seluruh model dilatih menggunakan data latih asli (belum dilakukan penyeimbangan kelas). Setiap model akan diujikan pada ketiga kondisi tersebut untuk memperoleh nilai *F1-score* (*weighted average*). Hasil dari masing-masing kondisi akan dibandingkan, dan versi model dengan *F1-score* tertinggi akan dipilih sebagai representasi terbaik dari setiap algoritma pada Skenario 1. Model-model terbaik inilah yang kemudian digunakan sebagai input pada Skenario Pengujian 2 dan 3.

2.3.2. Skenario Pengujian 2: Oversampling SMOTE

Synthetic Minority Over-sampling Technique (SMOTE) adalah suatu teknik yang melakukan oversampling pada kelas minoritas dengan cara menghasilkan sintesis baru (bukan duplikasi) di sepanjang garis yang menghubungkan sampel kelas minoritas terdekat. Hal ini bertujuan untuk menciptakan distribusi kelas yang lebih seimbang, misalnya rasio 1:1 tanpa hanya menduplikasi data minoritas. Skenario ini secara khusus bertujuan untuk mengevaluasi dampak SMOTE dalam mengatasi masalah imbalanced data terhadap performa model prediksi. Data latih pada skenario 1 akan di-oversample menggunakan SMOTE yang selanjutnya akan dilatih pada kelima algoritma klasifikasi (*LightGBM*, *Random Forest*, *Decision Tree*, *KNN*, dan *MLP*). Evaluasi kinerja akhir setiap model akan dilakukan pada data uji asli (yang tidak di-resample) untuk mengukur peningkatan efektivitas, terutama pada metrik *Recall* dan *F1-Score* kelas minoritas.

2.3.3. Skenario Pengujian 3: Oversampling ADASYN

Adaptive Synthetic Sampling (ADASYN) adalah varian dari teknik oversampling sintetis yang bertujuan untuk meningkatkan akurasi model, terutama pada data yang sangat tidak seimbang. Berbeda dengan SMOTE yang menghasilkan sampel secara seragam, ADASYN menghasilkan lebih banyak sampel sintetis untuk sampel kelas minoritas yang dianggap lebih sulit diklasifikasikan (*hard samples*), yaitu sampel yang terletak dekat dengan batas kelas mayoritas. Skenario ini bertujuan untuk membandingkan efektivitas ADASYN dengan SMOTE (Skenario 2) dalam penanganan imbalanced data. Data pelatihan yang telah di-Feature Selection akan di-oversample menggunakan ADASYN untuk mencapai distribusi kelas yang seimbang. Kelima algoritma klasifikasi (LightGBM, Random Forest, Decision Tree, KNN, dan MLP) akan dilatih menggunakan data pelatihan yang telah diseimbangkan oleh ADASYN. Evaluasi kinerja akhir setiap model akan dilakukan pada data uji asli (yang tidak di-resample). Perbandingan langsung antara hasil Skenario 2 dan Skenario 3, dengan fokus pada metrik *Recall* dan *F1-Score*, akan menyimpulkan metode oversampling mana yang paling optimal untuk prediksi *loan default*.

3. HASIL DAN PEMBAHASAN

3.1. Skenario Pengujian 1

Skenario ini berfokus pada optimasi fitur sebelum penanganan *imbalanced data*. Tahap ini bertujuan untuk mengevaluasi apakah mengurangi redundansi atau dimensi fitur, baik melalui pemilihan fitur spesifik maupun proyeksi fitur (PCA), dapat meningkatkan efisiensi komputasi dan akurasi prediktif dasar model Machine Learning pada data asli.

3.1.1. Kinerja Model pada Data Asli (Baseline)

Sub-bab ini menyajikan hasil awal kinerja kelima model yang dilatih menggunakan seluruh fitur pada data latih asli (belum melalui Feature Selection, PCA, maupun oversampling). Hasil ini berfungsi sebagai baseline komparatif untuk mengevaluasi efektivitas teknik preprocessing selanjutnya.

Tabel 3.1.1. Hasil Evaluasi Model pada Data Asli

Model Klasifikasi	F1-Score (weighted avg)	Recall (Kelas Minoritas - Default)
KNN	0.90	0.01
Decision Tree	0.82	0.12
Random Forest	0.91	0.00
LightGBM	0.68	0.30
MLP	0.91	0.00

Secara keseluruhan, model Random Forest dan MLP menunjukkan kinerja F1-Score (*weighted average*) terbaik (0.91), sementara LightGBM memiliki F1-Score terendah (0.68). Namun, fokus utama, yaitu Recall kelas minoritas (*Default*), menunjukkan ketidakseimbangan yang parah (bias):

1. Recall Sangat Rendah: Random Forest, MLP, dan KNN hampir sepenuhnya gagal mengidentifikasi kasus Default, dengan nilai Recall 0.00 hingga 0.01. Hal ini mengindikasikan bahwa model-model ini bias dan cenderung memprediksi semua kasus sebagai kelas Mayoritas.
2. Recall Tertinggi: Model LightGBM, meskipun memiliki F1-Score terendah, justru paling efektif dalam deteksi Default dengan Recall 0.30.

Rendahnya Recall pada sebagian besar model menjustifikasi perlunya penerapan teknik oversampling (SMOTE dan ADASYN) pada skenario berikutnya. Intervensi ini diharapkan dapat meningkatkan sensitivitas model terhadap kelas minoritas.

3.1.2. Dampak Feature Selection

Tujuan pengujian bertujuan untuk mengevaluasi dampak *Feature Selection* (FS) pada kinerja model.

Tabel 3.1.2. Hasil Evaluasi Model dengan Feature Selection

Model Klasifikasi	F1-Score (weighted avg)	Recall (Kelas Minoritas - Default)
KNN	0.90	0.00
Decision Tree	0.82	0.13
Random Forest	0.91	0.00
LightGBM	0.65	0.35
MLP	0.85	0.07

Proses seleksi fitur menggunakan ANOVA F-value (melalui SelectKBest) bekerja dengan menyaring fitur-fitur yang memiliki varians antar-kelas paling signifikan. Penerapan Feature Selection (FS) ini menghasilkan dampak yang beragam:

1. Stabilitas F1-Score (Weighted Avg): Model KNN, Decision Tree, dan Random Forest menunjukkan stabilitas sempurna pada F1-Score (*weighted avg*). Hal ini mencerminkan ketahanan algoritma-algoritma tersebut terhadap dimensi fitur yang lebih rendah, di mana tidak mudah terganggu oleh penghapusan fitur non-dominan dan cenderung konsisten dengan keputusan global mereka.
2. Penurunan F1-Score: Model LightGBM dan MLP mengalami penurunan F1-Score yang signifikan (LightGBM -0.03; MLP -0.06). Ini mengindikasikan bahwa fitur yang dihilangkan oleh FS sebenarnya penting bagi kedua model ini untuk kinerja klasifikasi *overall* terbaik.
3. Peningkatan Recall Minoritas:
 - LightGBM menunjukkan peningkatan *Recall* minoritas yang substansial, dari 0.30 menjadi 0.35. MLP juga mengalami peningkatan *Recall* dari 0.00 menjadi 0.07. Penghapusan fitur yang dianggap "lemah" secara statistik membantu mengurangi redundansi data yang sebelumnya menyembunyikan pola-pola kelas minoritas yang langka. Dengan berkurangnya ruang fitur dan lebih berfokus pada prediktor yang paling diskriminatif, model menjadi lebih sensitif dalam mengidentifikasi nasabah *default* (*Recall* meningkat).
 - Decision Tree sedikit meningkat (dari 0.12 menjadi 0.13).
 - Sebaliknya, KNN mengalami penurunan *Recall* dari 0.01 menjadi 0.00.

Berdasarkan hasil ini, FS terbukti **tidak efektif** dalam meningkatkan F1-Score *weighted average* secara umum, bahkan merugikan LightGBM dan MLP. Namun, FS berhasil meningkatkan Recall Minoritas untuk LightGBM dan MLP.

3.1.3. Dampak Reduksi Dimensi dengan PCA

Sub-bab ini mengevaluasi Principal Component Analysis (PCA) sebagai alternatif Feature Selection untuk mereduksi dimensi data latih.

Tabel 3.1.3. Hasil Evaluasi Model dengan PCA

Model Klasifikasi	F1-Score (weighted avg)	Recall (Kelas Minoritas - Default)
-------------------	-------------------------	------------------------------------

KNN	0.90	0.01
Decision Tree	0.82	0.11
Random Forest	0.91	0.00
LightGBM	0.71	0.30
MLP	0.83	0.09

Dalam pengujian ini, PCA dikonfigurasi untuk mempertahankan sejumlah varians tertentu, menghasilkan 28 komponen utama. PCA bekerja dengan mentransformasikan fitur-fitur asli menjadi komponen utama yang tidak berkorelasi (*orthogonal*), yang secara efektif mereduksi *noise* dan multikolinearitas dalam dataset. Analisis komparatif kinerja model dengan PCA (Tabel 1.3) dibandingkan dengan kondisi Baseline (Tabel 1.1) dan FS (Tabel 1.2) adalah sebagai berikut:

1. Stabilitas Model Ensemble dan KNN: Model KNN (0.90) dan Random Forest (0.91) menunjukkan F1-Score yang stabil di antara ketiga skenario (Baseline, FS, dan PCA). Ini menunjukkan bahwa integritas ensemble dan metode berbasis jarak tidak banyak dipengaruhi oleh transformasi data.
2. Peningkatan F1-Score pada LightGBM: LightGBM menunjukkan peningkatan F1-Score yang signifikan dari 0.68 (Baseline) menjadi 0.71 dengan PCA. Ini adalah satu-satunya skenario preprocessing dimensi (dari FS dan PCA) yang berhasil meningkatkan F1-Score LightGBM. Penyederhanaan ruang fitur oleh PCA membantu algoritma berbasis *tree* untuk menemukan ambang batas pemisahan (*split thresholds*) yang lebih optimal.
3. Dampak pada MLP: MLP mengalami penurunan F1-Score dari 0.91 (Baseline) menjadi 0.83 dengan PCA, meski Recall minoritas meningkat dari 0.00 menjadi 0.09. Ini menunjukkan transformasi linear PCA dapat menghilangkan detail struktur data non-linear yang krusial bagi lapisan tersembunyi (*hidden layers*) untuk membangun representasi fitur yang mendalam.
4. Recall Minoritas:
 - KNN dan Random Forest tetap stagnan pada nilai sangat rendah (0.00 atau 0.01) menunjukkan bahwa reduksi dimensi saja tidak cukup untuk mengatasi masalah bias kelas yang ekstrem dalam dataset *loan default*.
 - Decision Tree mencapai Recall tertinggi dengan FS (0.13).
 - LightGBM mencapai Recall minoritas tertinggi dengan FS (0.35), bukan PCA.
 - MLP menunjukkan Recall minoritas tertinggi di Skenario 1 dengan PCA (0.09), yang menandakan bahwa komponen utama PCA menonjolkan beberapa pola minoritas yang sebelumnya tersembunyi.

Berdasarkan hasil akhir skenario 1, PCA terbukti lebih unggul bagi beberapa model dimana berhasil meningkatkan F1-Score LightGBM dari 0.68 (Baseline) menjadi 0.71, dan mencapai Recall minoritas tertinggi untuk MLP. Berdasarkan kriteria ini, KNN, Decision Tree, Random Forest, dan LightGBM akan menggunakan data yang direduksi dimensi oleh PCA sebagai input untuk oversampling. Namun, model MLP ditetapkan menggunakan data kondisi Baseline. Hal ini dikarenakan, meskipun Recall MLP meningkat dengan PCA, kerugian F1-Score (penurunan dari 0.91 ke 0.83) dianggap terlalu besar. Di mana mempertahankan F1-Score tertinggi dianggap lebih krusial sebelum melanjutkan ke tahap penyeimbangan kelas.

3.2. Skenario Pengujian 2: Oversampling SMOTE

Skenario ini secara khusus bertujuan untuk mengevaluasi dampak *Synthetic Minority Over-sampling Technique* (SMOTE) dalam mengatasi masalah imbalanced data terhadap performa model prediksi.

Tabel 3.2. Hasil Evaluasi Model dengan SMOTE

Model Klasifikasi	F1-Score (weighted avg)	Recall (Kelas Minoritas - Default)
KNN	0.80	0.15
Decision Tree	0.78	0.16
Random Forest	0.90	0.01
LightGBM	0.88	0.04
MLP	0.80	0.11

Hasil ini menunjukkan efektivitas SMOTE dalam meningkatkan kemampuan deteksi pada model yang sebelumnya bias. KNN dan MLP memperlihatkan peningkatan Recall minoritas yang signifikan (dari 0.01 menjadi 0.15 untuk KNN, dan 0.00 menjadi 0.11 untuk MLP), membuktikan bahwa penambahan data sintetis mampu memperluas cakupan batas keputusan model dalam mengenali kelas minoritas.

Namun, peningkatan Recall ini juga diikuti dengan penurunan tajam pada F1-Score (weighted avg). F1-Score KNN dan MLP turun dari 0.90-0.91 menjadi 0.80, yang mengindikasikan bahwa sampel sintetis SMOTE meningkatkan False Positives (mengurangi Precision), sehingga mengurangi akurasi keseluruhan. Hal ini dikarenakan sampel sintetis yang dibuat secara linear di antara titik-titik minoritas cenderung menciptakan tumpang tindih (*overlap*) dengan ruang kelas mayoritas.

Hanya Random Forest yang berhasil mempertahankan F1-Score tinggi (0.90), namun ironisnya, *Recall* minoritasnya tetap stagnan di 0.01, menunjukkan algoritma ini tidak merespons perubahan distribusi kelas yang dihasilkan SMOTE. Hasil ini kemungkinan disebabkan oleh mekanisme *bagging* dan pemilihan fitur acak yang dimiliki Random Forest cenderung lebih memprioritaskan konsistensi pola global dibandingkan fluktuasi lokal yang diperkenalkan oleh data sintetis minoritas.

Kasus yang paling anomali terjadi pada LightGBM, di mana F1-Score-nya meningkat drastis dari 0.71 menjadi 0.88. Namun, peningkatan ini disertai dengan anjloknya *Recall* minoritas dari 0.35 menjadi hanya 0.04. Hal ini menunjukkan bahwa data sintetis SMOTE mengubah fitur batas keputusan LightGBM, sehingga meningkatkan kinerja klasifikasi rata-rata (F1 *weighted*) tetapi sangat merusak kemampuan spesifiknya untuk mendeteksi *Default*. Hasil kinerja terbaik dari Skenario 2 ini akan diidentifikasi dan dibandingkan dengan ADASYN di skenario selanjutnya.

3.3. Skenario Pengujian 3: Oversampling ADASYN

Skenario terakhir ini bertujuan untuk membandingkan efektivitas ADASYN (Adaptive Synthetic Sampling) dengan SMOTE dalam penanganan imbalanced data.

Tabel 3.3. Hasil Evaluasi Model dengan ADASYN

Model Klasifikasi	F1-Score (weighted avg)	Recall (Kelas Minoritas - Default)
KNN	0.57	0.41

Decision Tree	0.69	0.27
Random Forest	0.86	0.04
LightGBM	0.69	0.25
MLP	0.81	0.14

Secara umum, ADASYN terbukti lebih agresif dalam meningkatkan Recall minoritas dibanding SMOTE, namun hal ini menyebabkan trade-off signifikan terhadap F1-Score keseluruhan. KNN mencatat peningkatan Recall terbesar dengan ADASYN, mencapai 0.41 (naik dari 0.15 pada SMOTE), sementara MLP juga menunjukkan Recall yang lebih tinggi yaitu 0.14 (naik dari 0.11 pada SMOTE).

Namun, peningkatan recall yang terjadi menghasilkan kerugian F1-Score (weighted avg) yang ekstrem pada setiap model. F1-Score KNN anjlok menjadi 0.57 (dari 0.80 pada SMOTE), dan Decision Tree turun menjadi 0.69 (dari 0.78 pada SMOTE). Penurunan tajam ini terjadi karena fokus ADASYN pada sampel minoritas yang sulit (*hard samples*) menghasilkan *noise* yang lebih tinggi di batas keputusan, secara signifikan merusak *Precision* model dan F1-Score keseluruhan. Model ensemble seperti LightGBM dan Random Forest menunjukkan pola yang serupa. LightGBM mencatat F1-Score 0.69 (dibandingkan 0.88 pada SMOTE) dengan Recall 0.25 (dibandingkan 0.04 pada SMOTE). Random Forest mempertahankan F1-Score relatif tinggi (0.86), tetapi Recall minoritasnya tetap rendah di 0.04. Secara keseluruhan, meskipun ADASYN berhasil mencapai Recall minoritas tertinggi untuk KNN dalam keseluruhan penelitian, SMOTE umumnya memberikan keseimbangan Recall dan F1-Score yang lebih baik untuk model-model non-ensemble yang lebih sederhana.

4. KESIMPULAN

Penelitian ini berhasil menganalisis dampak optimasi data terhadap kinerja model prediksi *loan default* melalui tiga skenario pengujian, yang menyimpulkan bahwa teknik reduksi dimensi seperti PCA hanya efektif pada model tertentu (seperti LightGBM dengan F1-Score 0,71) namun gagal mengatasi rendahnya *Recall* kelas minoritas tanpa adanya penyeimbangan data. Meskipun terdapat *trade-off* di mana ADASYN lebih agresif meningkatkan deteksi *default*, SMOTE dinilai sebagai pilihan yang lebih stabil dan aman untuk menjaga keseimbangan kinerja model secara keseluruhan. Untuk pengembangan selanjutnya, disarankan penggunaan teknik *hybrid sampling* (kombinasi *oversampling* dan *undersampling*) untuk menekan *noise* serta optimasi parameter model yang lebih mendalam guna memaksimalkan metrik *Recall* kelas *default*. Hal ini krusial untuk diterapkan dalam konteks risiko perbankan, sebab meminimalkan *False Negative* merupakan prioritas utama untuk menghindari kerugian finansial yang signifikan dibandingkan dengan dampak yang ditimbulkan oleh *False Positive*.

REFERENSI

- [1] Akinjole A, et al. Ensemble-Based Machine Learning Algorithm for Loan Default Prediction. *Mathematics*. 2024; 12(21): 3423.
- [2] Aruleba I, et al. Enhanced Credit Risk Prediction Using Deep Learning and SMOTE-ENN. *Heliyon*. 2025; n.v.: n.p.
- [3] Kuizinienė D, et al. A Comparative Study of Feature Selection and Dimensionality Reduction for Financial Distress Classification. *Journal of Big Data*. 2024; n.v.: n.p.
- [4] Monje L, et al. Machine Learning XAI for Early Loan Default Prediction. *Computational Economics*. 2025; n.v.: n.p.
- [5] Owusu E, Quainoo R, Mensah S, Appati JK. A Deep Learning Approach for Loan Default Prediction Using Imbalanced Dataset. *International Journal of Intelligent Information Technologies*. 2023; n.v.: n.p.
- [6] Shobayo O, Popoola J, Okoyeigbo O, Ogunleye B. Ensemble-Based Machine Learning Algorithm for Loan Default Risk Prediction. *Mathematics*. 2024; 12(21): 3423.
- [7] Souadda L, et al. Optimizing Credit Risk Prediction for Peer-to-Peer Lending: Feature Stability and LightGBM. *FinTech*. 2025; 7(3): 35.
- [8] Zhang X, et al. Data-Driven Loan Default Prediction: A Machine Learning Evaluation. *Systems*. 2025; 13(7): 581.
- [9] Zhu L, Qiu D, Ergu D, Ying C, Liu K. Loan Default Prediction Based on Convolutional Neural Network and LightGBM. *International Journal of Intelligent Information Technologies*. 2023; 19(1): n.p.
- [10] An Explainable ADASYN-Based Focal Loss Approach for Credit Scoring. *International Journal of Finance & Economics*. 2025; n.v.: n.p.
- [11] Madaan M, Kumar A, Keshri C, Jain R, Nagrath P. Loan Default Prediction Using Decision Trees and Random Forest: A Comparative Study. *IOP Conference Series: Materials Science and Engineering*. Online. 2021: 012042.
- [12] Brandt J. A Comparative Review of SMOTE and ADASYN in Imbalanced Classification. Bachelor Thesis. Sweden: DIVA Portal; 2021.
- [13] Owusu-Ansah EGJ. Machine Learning Analysis of Synthetic Minority/Oversampling Techniques for Loan/Credit Datasets. MSc Thesis. n.p.: n.p.; 2024.
- [14] Soomro A, et al. *Loan Default Prediction Using Machine Learning (2020–2023): A Systematic Literature Review*. Pakistan Journal of Life and Social Sciences. 2024.
- [15] Kang ZZ, Teh SY, Tan SYG, Ng WC. Loan Default Prediction Using Machine Learning Algorithms. *ResearchGate Preprint*. 2024.
- [16] Saha T, Biswas SK, Sanyal S, Patro B, Purkayastha B. Credit Risk Prediction Using Machine Learning Analytics: An Ensemble Model. *ResearchGate Preprint*. 2023.
- [17] Goyal M, Arora A. Credit Risk Assessment Using Hybrid XGBoost–SMOTE Model for Imbalanced Financial Data. *Expert Systems with Applications*. 2024; 245: 122123.